



CIENCIAS DE LA COMPUTACIÓN

1ACC0216 – FUNDAMENTOS DE DATA SCIENCE

TB1

Integrantes:

- Francesco Andre Meza Dagnino
- Alejandro Jhoshua García Hernández
- Ian Landauro La Rosa

2026-10

Índice

Índice.....	2
1. CASO DE ANÁLISIS.....	3
1.1 Origen de los Datos.....	3
1.2 Credibilidad y Recolección.....	3
2.3 Casos de Uso Aplicables.....	3
2. CONJUNTO DE DATOS (DATA SET).....	5
3. ANÁLISIS EXPLORATORIO DE DATOS (EDA).....	8
3.1 Cargar Datos.....	8
3.2 Inspeccionar Datos.....	8
3.3 Ajustes y Transformaciones.....	9
3.4 Pre-procesar Datos.....	10
3.4.1 Identificación y Tratamiento de Datos Faltantes:.....	10
3.4.2 Detección y Tratamiento de Outliers.....	11
3.5 Visualización de Datos.....	11
3.6 Justificación.....	17
4. CONCLUSIONES.....	18
4.1 Conclusiones del Análisis.....	18
4.2 Patrones y Tendencias.....	18
4.3 Recomendaciones.....	19
5. ENLACE A REPOSITORIO DE GITHUB.....	20
Referencias.....	21

1. CASO DE ANÁLISIS

1.1 Origen de los Datos

El conjunto de datos utilizado para este análisis se titula "Hotel Booking Demand". Fue recopilado originalmente por Nuno Antonio, Ana Almeida y Luis Nunes, y publicado en el año 2019 a través de la revista Data in Brief y la plataforma Kaggle. La información proviene de dos hoteles reales situados en Portugal: un Resort Hotel (ubicado en la región de Algarve) y un City Hotel (ubicado en la ciudad de Lisboa). Los datos cubren un periodo de dos años, desde el 1 de julio de 2015 hasta el 31 de agosto de 2017 (Antonio et al., 2019).

1.2 Credibilidad y Recolección

La credibilidad de este dataset es muy alta debido a que los datos no provienen de encuestas o estimaciones, sino de registros administrativos reales extraídos directamente de los sistemas de gestión hotelera (PMS o Property Management Systems) de ambas instituciones.

Es importante mencionar que, para fines didácticos en este curso, el archivo ha sido modificado intencionalmente para incluir "ruido", como valores nulos (NA) y datos atípicos (outliers), lo que requiere un proceso riguroso de limpieza y preprocesamiento antes de realizar el análisis estadístico (Antonio et al., 2019).

2.3 Casos de Uso Aplicables

El análisis de estos datos es fundamental para diversos actores del sector turístico:

- **Interesados:** Gerentes generales de hoteles, departamentos de Marketing, agencias de viajes y especialistas en *Revenue Management*.
- **Problemas y Necesidades que responde:**
 - **Predicción de Cancelaciones:** Identificar qué tipo de reservas tienen mayor riesgo de ser canceladas para implementar políticas de pago anticipado.
 - **Optimización de Inventario:** Planificar la cantidad de personal necesario y la compra de suministros según la demanda estacional.
 - **Segmentación de Clientes:** Diferenciar el comportamiento de reserva entre familias con niños y viajeros de negocios para crear ofertas personalizadas.

- **Logística:** Determinar la necesidad de espacios de estacionamiento y servicios adicionales (como cunas o tipos de comida) según el perfil del huésped

2. CONJUNTO DE DATOS (DATA SET)

A continuación, se describen las variables principales identificadas en el archivo hotel_bookings.csv:

Nombre de la Variable	Tipo de Dato (R)	Clasificación Estadística	Descripción Breve
hotel	Factor / Character	Cualitativa Nominal	Tipo de hotel: "Resort Hotel" o "City Hotel".
is_canceled	Integer	Cualitativa Nominal (Binaria)	Indica si la reserva fue cancelada (1) o no (0).
lead_time	Integer	Cuantitativa Discreta	Días transcurridos entre la reserva y la llegada.
arrival_date_year	Integer	Cualitativa Ordinal	Año de la fecha de llegada.
arrival_date_month	Factor / Character	Cualitativa Ordinal	Mes de la fecha de llegada.
stays_in_weekend_nights	Integer	Cuantitativa Discreta	Noches de sábado o domingo que el huésped se quedó.
stays_in_week_nights	Integer	Cuantitativa Discreta	Noches de lunes a viernes que el huésped se quedó.
adults	Integer	Cuantitativa Discreta	Número de adultos.

children	Integer	Cuantitativa Discreta	Número de niños.
babies	Integer	Cuantitativa Discreta	Número de bebés.
meal	Factor / Character	Cualitativa Nominal	Tipo de comida reservada (Ej: BB - Bed & Breakfast).
country	Factor / Character	Cualitativa Nominal	País de origen del huésped.
market_segment	Factor / Character	Cualitativa Nominal	Segmento de mercado (Ej: Direct, Online TA).
distribution_channel	Factor / Character	Cualitativa Nominal	Canal de distribución de la reserva.
is_repeated_guest	Integer	Cualitativa Nominal (Binaria)	Si es un cliente recurrente (1) o no (0).
reserved_room_type	Factor / Character	Cualitativa Nominal	Código del tipo de habitación reservada.
assigned_room_type	Factor / Character	Cualitativa Nominal	Código del tipo de habitación asignada.
deposit_type	Factor / Character	Cualitativa Nominal	Indica si se hizo depósito (No Deposit, Refundable, Non Refund).

agent	Character / ID	Cualitativa Nominal	ID de la agencia de viajes que hizo la reserva.
company	Character / ID	Cualitativa Nominal	ID de la compañía que hizo la reserva o paga la factura.
customer_type	Factor / Character	Cualitativa Nominal	Tipo de reserva (Transient, Group, etc.).
adr	Numeric	Cuantitativa Continua	Tarifa diaria promedio (Average Daily Rate).
required_car_parking_spaces	Integer	Cuantitativa Discreta	Número de espacios de estacionamiento requeridos.
total_of_special_requests	Integer	Cuantitativa Discreta	Número de peticiones especiales (Ej: cama extra).
reservation_status	Factor / Character	Cualitativa Nominal	Estado final (Canceled, Check-out, No-Show).
reservation_status_date	Date	Cualitativa Ordinal	Fecha en la que se actualizó el último estado.

3. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

3.1 Cargar Datos

Para iniciar el análisis, se procede a limpiar la memoria del entorno de trabajo y cargar el dataset. Se utilizan los parámetros `header = TRUE` para reconocer los nombres de las columnas y `stringsAsFactors = FALSE` para evitar que R transforme automáticamente los textos en factores antes de su limpieza.

```
rm(list=ls())
```

```
df <- read.csv("hotel_bookings.csv", header = TRUE, stringsAsFactors = FALSE)
```

```
head(df)
```

```
> rm(list=ls())
>
> df <- read.csv("hotel_bookings.csv", header = TRUE, stringsAsFactors = FALSE)
>
> head(df)
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month
1	Resort Hotel	0	342	2015	July
2	Resort Hotel	0	737	2015	July
3	Resort Hotel	0	7	2015	July
4	Resort Hotel	0	13	2015	July
5	Resort Hotel	0	14	2015	July
6	Resort Hotel	0	14	2015	July

	arrival_date_week_number	arrival_date_day_of_month	stays_in_weekend_nights
1	27	1	0
2	27	1	0
3	27	1	0
4	27	1	0
5	27	1	0
6	27	1	0

	stays_in_week_nights	adults	children	babies	meal	country	market_segment	distribution_channel
1	0	2	0	0	BB	PRT	Direct	Direct
2	0	2	0	0	BB	PRT	Direct	Direct
3	1	1	0	0	BB	GBR	Direct	Direct
4	1	1	0	0	BB	GBR	Corporate	Corporate
5	2	2	0	0	BB	GBR	Online TA	TA/TO
6	2	2	0	0	BB	GBR	Online TA	TA/TO

	is_repeated_guest	previous_cancellations	previous_bookings_not_canceled	reserved_room_type
1	0		0	C
2	0		0	C
3	0		0	A
4	0		0	A
5	0		0	A
6	0		0	A

3.2 Inspeccionar Datos

Se realiza una inspección inicial para comprender la estructura del dataset, identificar el tipo de variables asignadas por R y detectar la presencia de valores nulos o registros duplicados.


```

str(df)

summary(df)

sum(duplicated(df))

> sum(duplicated(df))
[1] 31994

> str(df)
'data.frame': 119390 obs. of 32 variables:
 $ hotel      : chr  "Resort Hotel" "Resort Hotel" "Resort Hotel" "Resort Hotel"
...
 $ is_canceled : int  0 0 0 0 0 0 0 0 1 1 ...
 $ lead_time   : int  342 737 7 13 14 14 0 9 85 75 ...
 $ arrival_date_year : int  2015 2015 2015 2015 2015 2015 2015 2015 2015 2015 ...
 $ arrival_date_month : chr  "July" "July" "July" "July" ...
 $ arrival_date_week_number : int  27 27 27 27 27 27 27 27 27 27 ...

> summary(df)
      hotel      is_canceled      lead_time      arrival_date_year      arrival_date_month
Length:119390   Min.   :0.0000   Min.   : 0   Min.   :2015   Length:119390
Class :character 1st Qu.:0.0000   1st Qu.: 18   1st Qu.:2016   Class :character
Mode  :character Median :0.0000   Median : 69   Median :2016   Mode  :character
                Mean  :0.3704   Mean  :104   Mean  :2016
                3rd Qu.:1.0000   3rd Qu.:160   3rd Qu.:2017
                Max.   :1.0000   Max.   :737   Max.   :2017

```

3.3 Ajustes y Transformaciones

Tras la inspección, se detecta que variables como hotel, arrival_date_month y meal deben ser tratadas como factores. Asimismo, se corrigen formatos de fecha y se eliminan duplicados para asegurar la integridad del análisis.

```

df <- unique(df)

df$hotel <- as.factor(df$hotel)
df$arrival_date_month <- as.factor(df$arrival_date_month)
df$meal <- as.factor(df$meal)
df$is_canceled <- as.factor(df$is_canceled)

df$reservation_status_date <- as.Date(df$reservation_status_date)

str(df)

```

```

> df <- unique(df)
>
> df$hotel <- as.factor(df$hotel)
> df$arrival_date_month <- as.factor(df$arrival_date_month)
> df$meal <- as.factor(df$meal)
> df$is_canceled <- as.factor(df$is_canceled)
>
> df$reservation_status_date <- as.Date(df$reservation_status_date)
>
> str(df)
'data.frame': 87396 obs. of 32 variables:
 $ hotel          : Factor w/ 2 levels "City Hotel","Resort Hotel": 2 2 2 2 2 2 2 2
2 2 ...
 $ is_canceled    : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 2 2 2 ...
 $ lead_time      : int 342 737 7 13 14 0 9 85 75 23 ...
 $ arrival_date_year : int 2015 2015 2015 2015 2015 2015 2015 2015 2015 2015 ...
 $ arrival_date_month : Factor w/ 12 levels "April","August",...: 6 6 6 6 6 6 6 6 6 6 ...
 $ arrival_date_week_number : int 27 27 27 27 27 27 27 27 27 27 ...
 $ arrival_date_day_of_month : int 1 1 1 1 1 1 1 1 1 1 ...
 $ stays_in_weekend_nights : int 0 0 0 0 0 0 0 0 0 0 ...
 $ stays_in_week_nights : int 0 0 1 1 2 2 2 3 3 4 ...
 $ adults         : int 2 2 1 1 2 2 2 2 2 2 ...
 $ children       : int 0 0 0 0 0 0 0 0 0 0 ...
 $ babies        : int 0 0 0 0 0 0 0 0 0 0 ...
 $ meal          : Factor w/ 5 levels "BB","FB","HB",...: 1 1 1 1 1 1 2 1 3 1 ...
 $ country       : chr "PRT" "PRT" "GBR" "GBR" ...

```

3.4 Pre-procesar Datos

3.4.1 Identificación y Tratamiento de Datos Faltantes:

Se identifican las columnas con valores nulos. Para este caso, se decide eliminar las filas con NAs si representan un porcentaje mínimo, o imputar la mediana en variables numéricas para no perder información valiosa.

```
colSums(is.na(df))
```

```
df$children[is.na(df$children)] <- median(df$children, na.rm = TRUE)
```

```

> colSums(is.na(df))
      hotel      is_canceled      lead_time
      0              0              0
arrival_date_year arrival_date_month arrival_date_week_number
      0              0              0
arrival_date_day_of_month stays_in_weekend_nights stays_in_week_nights
      0              0              0
      adults      children      babies
      0              4              0
      meal      country      market_segment
      0              0              0
distribution_channel is_repeated_guest previous_cancellations
      0              0              0
previous_bookings_not_canceled reserved_room_type assigned_room_type
      0              0              0
      booking_changes      deposit_type      agent
      0              0              0
      company      days_in_waiting_list      customer_type
      0              0              0
      adr      required_car_parking_spaces      total_of_special_requests
      0              0              0
reservation_status reservation_status_date
      0              0
>
> df$children[is.na(df$children)] <- median(df$children, na.rm = TRUE)

```


3.4.2 Detección y Tratamiento de Outliers

Se utilizan diagramas de caja (boxplots) para identificar valores atípicos en la variable adr (tarifa diaria). Para mitigar su impacto, se aplica la técnica de Winsorización, limitando los valores extremos al percentil 95.

```
boxplot(df$adr, main="Detección de Outliers en ADR", col="orange")

limite_superior <- quantile(df$adr, 0.95, na.rm = TRUE)
df$adr[df$adr > limite_superior] <- limite_superior

boxplot(df$adr, main="ADR después de Winsorización", col="lightgreen")
```




3.5 Visualización de Datos

1. Reservas por tipo de hotel

- **Hallazgo:** Se observa que el "City Hotel" concentra el mayor volumen de reservas en comparación con el "Resort Hotel", lo que indica una mayor rotación en entornos urbanos.
- **Código R:**


```
ggplot(df, aes(x = hotel, fill = hotel)) +  
  geom_bar() +  
  labs(title = "Cantidad de Reservas por Tipo de Hotel", x = "Hotel", y = "Total")
```



2. Demanda de reservas en el tiempo

- **Hallazgo:** Existe un crecimiento constante de reservas desde 2015 a 2016, con picos marcados que sugieren una recuperación o expansión del mercado.
- **Código R:**

```
ggplot(df, aes(x = arrival_date_month, group = arrival_date_year, color = as.factor(arrival_date_year))) +
  geom_line(stat = "count") +
  labs(title = "Tendencia de Reservas por Mes y Año", x = "Mes", y = "Cantidad")
```




3. Temporadas de reserva (Meses)

- **Hallazgo:** Hallazgo: Los meses de julio y agosto presentan la mayor afluencia de huéspedes, coincidiendo con la temporada de vacaciones de verano en Europa.

- **Código R:**

```
ggplot(df, aes(x = arrival_date_month)) +  
  geom_bar(fill = "steelblue") +  
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +  
  labs(title = "Distribución de Reservas por Mes", x = "Mes", y = "Total")
```




4. Reservas por noches de fin de semana y semana

- **Hallazgo:** La mayoría de las estancias son cortas (1-3 noches), predominando las pernoctaciones en días de semana sobre los fines de semana.

- **Código R:**


```
ggplot(df, aes(x = stays_in_weekend_nights, y = stays_in_week_nights)) +  
  geom_jitter(alpha = 0.1, color = "darkgreen") +  
  labs(title = "Relación de Noches de Fin de Semana vs Semana")
```



5. Reservas con niños y/o bebés

- **Hallazgo:** La gran mayoría de las reservas son solo de adultos. Las familias representan un segmento pequeño pero importante que suele preferir el Resort Hotel.
- **Código R:**

```
df$tiene_ninos <- ifelse(df$children > 0 | df$babies > 0, "Con Niños", "Solo Adultos")
ggplot(df, aes(x = tiene_ninos, fill = tiene_ninos)) +
  geom_bar() +
  labs(title = "Proporción de Reservas con Menores")
```




6. Espacios de estacionamiento requeridos

- **Hallazgo:** Un porcentaje mínimo de huéspedes solicita estacionamiento, lo que sugiere que la mayoría utiliza transporte público o servicios de traslado .

- **Código R:**

```
ggplot(df, aes(x = as.factor(required_car_parking_spaces))) +  
  geom_bar(fill = "purple") +  
  labs(title = "Demanda de Estacionamientos", x = "Espacios", y = "Frecuencia")
```



7. Cancelaciones por tipo de hotel

- **Hallazgo:** El City Hotel no solo tiene más reservas, sino también una tasa de cancelación significativamente más alta en comparación con el Resort Hotel.

- **Código R:**


```
ggplot(df, aes(x = hotel, fill = is_canceled)) +  
  geom_bar(position = "fill") +  
  labs(title = "Proporción de Cancelaciones por Hotel", y = "Proporción")
```



8. Pregunta del equipo: ¿Cómo influye el 'lead_time' en las cancelaciones?

- **Justificación:** Queremos saber si las personas que reservan con mucha anticipación tienen más probabilidades de arrepentirse.
- **Hallazgo:** Las reservas canceladas muestran un **lead_time** mediano mucho más alto, lo que confirma que a mayor antelación, mayor riesgo de cancelación.
- **Código R:**

```
ggplot(df, aes(x = is_canceled, y = lead_time, fill = is_canceled)) +  
  geom_boxplot() +  
  labs(title = "Antelación de Reserva vs Cancelación", x = "¿Cancelado?", y = "Días de Antelación")
```

3.6 Justificación

Para asegurar la calidad del análisis, se seleccionaron los gráficos siguiendo estos criterios técnicos:

1. **Gráficos de Barras (geom_bar):** Utilizados para variables categóricas (hotel, mes, niños) porque permiten comparar frecuencias de forma clara y directa.
2. **Gráficos de Líneas (geom_line):** Elegidos para la demanda temporal porque facilitan la visualización de tendencias y ciclos estacionales.
3. **Diagramas de Dispersión/Jitter (geom_jitter):** Debido a que los datos de noches son números enteros, el "jitter" evita que los puntos se encimen, permitiendo ver la densidad de las estancias.
4. **Diagramas de Caja (geom_boxplot):** Ideales para comparar la distribución de una variable numérica (lead_time) frente a una categoría (is_canceled), permitiendo ver medianas y dispersión.
5. **Gráficos de Barras Apiladas al 100% (position = "fill"):** Utilizados en cancelaciones para comparar proporciones relativas, independientemente del volumen total de cada hotel.

4. CONCLUSIONES

4.1 Conclusiones del Análisis

Tras realizar el Análisis Exploratorio de Datos (EDA) sobre el dataset de demanda hotelera, se presentan las siguientes conclusiones fundamentadas:

- **Segmentación y Demanda:** El City Hotel presenta un volumen de reservas significativamente mayor que el Resort Hotel. Sin embargo, esto no implica necesariamente mayor rentabilidad, ya que el City Hotel también registra la mayor tasa de cancelaciones, lo que genera inestabilidad en la planificación de ingresos.
- **Temporalidad Crítica:** Se ha identificado una estacionalidad marcada en los meses de julio y agosto. Este patrón es consistente con el comportamiento del turismo en Portugal, donde la temporada de verano europeo dicta el pico de demanda, permitiendo a la gerencia prever aumentos en los precios (ADR) durante estos meses.
- **Perfil del Huésped:** La mayoría de las reservas corresponden a adultos sin niños. El segmento de familias, aunque es menor, tiende a elegir estancias más largas y se concentra en el Resort Hotel, lo que sugiere que las campañas de marketing familiar deben enfocarse exclusivamente en este tipo de establecimiento.
- **Logística y Servicios:** La baja demanda de espacios de estacionamiento indica que los huéspedes prefieren medios de transporte alternativos o que los hoteles están ubicados en zonas con alta conectividad, lo cual es un hallazgo clave para no invertir capital innecesario en infraestructura de parqueo.

4.2 Patrones y Tendencias

- **Tendencia de Cancelación:** Existe una correlación positiva entre el lead_time (antelación de la reserva) y la probabilidad de cancelación. Las reservas realizadas con más de 150 días de antelación tienen un riesgo mucho más alto de ser dadas de baja.
- **Comportamiento de Estancia:** Se observa una tendencia a estancias cortas durante los días de semana en el hotel urbano, mientras que en el resort las estancias suelen abarcar fines de semana completos, confirmando el uso recreativo del segundo.

4.3 Recomendaciones

- **Políticas de Cancelación:** Implementar tarifas "No Reembolsables" obligatorias para aquellas reservas cuyo lead_time supere los 120 días, con el fin de mitigar el riesgo de pérdida de inventario.
- **Estrategia de Precios (ADR):** Dado el pico de demanda en verano, se recomienda aplicar estrategias de Dynamic Pricing más agresivas en agosto para maximizar el margen de beneficio.
- **Fidelización:** Dado que el número de huéspedes recurrentes es bajo (según la variable is_repeated_guest), se sugiere crear un programa de lealtad que ofrezca descuentos directos en la segunda reserva para aumentar la retención.

5. ENLACE A REPOSITORIO DE GITHUB

<https://github.com/frxxnz/1ACC0216-TB1-2026-1>

Referencias

- Antonio, N., Almeida, A., & Nunes, L. (2019). Hotel booking demand datasets. *Data in Brief*, 22, 41-49. <https://doi.org/10.1016/j.dib.2018.11.126>
- Kaggle. (2019). *Hotel booking demand*. <https://www.kaggle.com/jessemostipak/hotel-booking-demand>
- Wickham, H., & Grolemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media.