

CIENCIAS DE LA COMPUTACIÓN

1ACC0216 – FUNDAMENTOS DE DATA SCIENCE

Trabajo Basado en Desempeño 1 (TB1)

Integrantes: Francesco Meza Dagnino | Alejandro García Hernández | Ian Landauro La Rosa

Ciclo: 2026-10

1. CASO DE ANÁLISIS

1.1 Origen de los Datos

"Hotel Booking Demand" (2019) de Nuno Antonio, Ana Almeida y Luis Nunes.

Registros reales de un **Resort Hotel** (Algarve) y un **City Hotel** (Lisboa) entre 2015 y 2017.

1.2 Credibilidad y Recolección

Alta fidelidad: Datos extraídos directamente de sistemas PMS (Property Management Systems).

Nota: Dataset modificado con ruido para fines académicos.



2.3 CASOS DE USO APLICABLES



Predicción de Cancelaciones

Identificar reservas con alto riesgo para optimizar políticas de prepago.



Optimización de Inventario

Planificación de personal y suministros basada en demanda estacional.



Segmentación de Clientes

Diferenciar perfiles (familias vs negocios) para ofertas personalizadas.

2. CONJUNTO DE DATOS (DATA SET)

Descripción de las variables principales (hotel_bookings.csv):

Variable	Tipo (R)	Clasificación	Descripción
hotel	Factor	Cualitativa Nominal	Tipo: Resort o City Hotel
is_canceled	Integer	Cualitativa Binaria	Cancelada (1) o No (0)
lead_time	Integer	Cuantitativa Discreta	Días previos a la llegada
adr	Numeric	Cuantitativa Continua	Tarifa diaria promedio
arrival_date_month	Factor	Cualitativa Ordinal	Mes de llegada
stays_in_week_nights	Integer	Cuantitativa Discreta	Noches de lun a vie

3.1 CARGAR Y 3.2 INSPECCIONAR DATOS

Carga del dataset asegurando integridad de tipos:

```
rm(list=ls())  
df <- read.csv("hotel_bookings.csv",  
  header = TRUE,  
  stringsAsFactors = FALSE)
```

Inspección inicial:

```
str(df)  
summary(df)  
sum(duplicated(df)) # 31,994 duplicados
```

- ✓ 119,390 observaciones iniciales.
- ✓ 32 variables detectadas.
- ✓ Alta presencia de registros duplicados que requieren limpieza.

3.3 AJUSTES Y TRANSFORMACIONES

Eliminación: Registros duplicados.

Casteo: Conversión de caracteres a factores.

Formato: Ajuste de columnas de fecha.

```
df <- unique(df)

df$hotel <- as.factor(df$hotel)
df$arrival_date_month <- as.factor(df$arrival_date_month)
df$meal <- as.factor(df$meal)
df$is_canceled <- as.factor(df$is_canceled)

df$reservation_status_date <- as.Date(df$reservation_status_date)

str(df)
```

3.4 PRE-PROCESAR DATOS

3.4.1 Datos Faltantes (NAs)

Imputación de la mediana para evitar pérdida de filas valiosas:


```
colSums(is.na(df))  
df$children[is.na(df$children)] <- median(df$children, na.rm = TRUE)
```

3.4.2 Outliers en ADR

Tratamiento vía **Winsorización** al percentil 95 para mitigar impacto de valores extremos.

```
boxplot(df$adr, main="Detección de Outliers en ADR", col="orange")  
  
limite_superior <- quantile(df$adr, 0.95, na.rm = TRUE)  
df$adr[df$adr > limite_superior] <- limite_superior  
  
boxplot(df$adr, main="ADR después de Winsorización", col="lightgreen")
```

ADR después de Winsorización



3.5 VISUALIZACIÓN DE DATOS



Reservas por Tipo de Hotel


Hallazgo: El "City Hotel" concentra el mayor volumen, indicando una rotación superior en entornos urbanos.

```
ggplot(df, aes(x = hotel, fill = hotel)) +  
  geom_bar() +  
  labs(title = "Cantidad de Reservas por Tipo de Hotel", x = "Hotel", y = "Total")
```

Tendencia Temporal

Hallazgo: Crecimiento marcado entre 2015 y 2016 con picos estacionales.

3.5 VISUALIZACIÓN DE DATOS




Demanda de reservas en el tiempo

Hallazgo: Existe un crecimiento constante de reservas desde 2015 a 2016, con picos marcados que sugieren una recuperación o expansión del mercado.

```
ggplot(df, aes(x = arrival_date_month, group = arrival_date_year, color = as.factor(arrival_date_year))) +  
  geom_line(stat = "count") +  
  labs(title = "Tendencia de Reservas por Mes y Año", x = "Mes", y = "Cantidad")
```

3.5 VISUALIZACIÓN DE DATOS




Temporadas de reserva (Meses)

Hallazgo: Los meses de julio y agosto presentan la mayor afluencia de huéspedes, coincidiendo con la temporada de vacaciones de verano en Europa.

```
ggplot(df, aes(x = arrival_date_month)) +  
  geom_bar(fill = "steelblue") +  
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +  
  labs(title = "Distribución de Reservas por Mes", x = "Mes", y = "Total")
```

3.5 VISUALIZACIÓN DE DATOS




Reservas por noches de fin de semana y semana

Hallazgo: La mayoría de las estancias son cortas (1-3 noches), predominando las pernoctaciones en días de semana sobre los fines de semana.

```
ggplot(df, aes(x = stays_in_weekend_nights, y = stays_in_week_nights)) +  
  geom_jitter(alpha = 0.1, color = "darkgreen") +  
  labs(title = "Relación de Noches de Fin de Semana vs Semana")
```

3.5 VISUALIZACIÓN DE DATOS




Reservas con niños y/o bebés

Hallazgo: La gran mayoría de las reservas son solo de adultos. Las familias representan un segmento pequeño pero importante que suele preferir el Resort Hotel.

```
df$tiene_ninos <- ifelse(df$children > 0 | df$babies > 0, "Con Niños", "Solo Adultos")
ggplot(df, aes(x = tiene_ninos, fill = tiene_ninos)) +
  geom_bar() +
  labs(title = "Proporción de Reservas con Menores")
```

3.5 VISUALIZACIÓN DE DATOS



Espacios de estacionamiento requeridos

Hallazgo: Un porcentaje mínimo de huéspedes solicita estacionamiento, lo que sugiere que la mayoría utiliza transporte público o servicios de traslado.

```
ggplot(df, aes(x = as.factor(required_car_parking_spaces))) +  
  geom_bar(fill = "purple") +  
  labs(title = "Demanda de Estacionamientos", x = "Espacios", y = "Frecuencia")
```

3.5 VISUALIZACIÓN DE DATOS



Cancelaciones por tipo de hotel

Hallazgo: El City Hotel no solo tiene más reservas, sino también una tasa de cancelación significativamente más alta en comparación con el Resort Hotel.


```
ggplot(df, aes(x = hotel, fill = is_canceled)) +  
  geom_bar(position = "fill") +  
  labs(title = "Proporción de Cancelaciones por Hotel", y = "Proporción")
```


3.5 VISUALIZACIÓN DE DATOS

Pregunta del equipo: ¿Cómo influye el 'lead_time' en las cancelaciones?

Justificación: Queremos saber si las personas que reservan con mucha anticipación tienen más probabilidades de arrepentirse.

Hallazgo: Las reservas canceladas muestran un lead_time mediano mucho más alto, lo que confirma que a mayor antelación, mayor riesgo de cancelación.



```
ggplot(df, aes(x = is_canceled, y = lead_time, fill = is_canceled)) +  
  geom_boxplot() +  
  labs(title = "Antelación de Reserva vs Cancelación", x = "¿Cancelado?", y = "Días de Antelación")
```

3.6 JUSTIFICACIÓN

Gráficos de Barras

Para variables categóricas (hotel, mes). Facilita comparación de frecuencias directas.

Diagramas de Caja

Ideales para comparar distribución numérica (Lead Time) frente a categorías (Cancelación).

Barras Apiladas 100%

Para comparar proporciones relativas de cancelaciones independientemente del volumen total.

4. CONCLUSIONES

4.1 Conclusiones del Análisis

- **Segmentación:** El City Hotel domina en volumen, pero posee una inestabilidad de ingresos mayor debido a sus altas tasas de cancelación.
- **Estacionalidad:** Los meses de Julio y Agosto dictan el pico de demanda (verano europeo), permitiendo alzas en el ADR.
- **Perfil:** La mayoría son adultos sin niños. Las familias prefieren el Resort Hotel para estancias largas.

4.2 Patrones y Tendencias

Existe una correlación positiva entre el tiempo de reserva (Lead Time) y la probabilidad de cancelación.

4.3 RECOMENDACIONES

Políticas de Pago

Implementar tarifas "No Reembolsables" para reservas con Lead Time superior a 120 días.

Dynamic Pricing

Estrategias agresivas de precios en Agosto para maximizar márgenes de beneficio.

Fidelización

Crear programas de lealtad dado que el número de huéspedes recurrentes es críticamente bajo.

5. ENLACE A REPOSITORIO: github.com/fundamentos-ds/TB1